

Clusterização de Regiões Conforme Qualidade da Água



Empresa Fictícia: HidroVerde Ambiental

Matéria: Projeto de Ciência de Dados 2

Data: 21/07/2024



Passo 1: Importar Dados

- **Fonte:** [Kaggle – Water Potability Dataset](#)
- **Total de amostras:** 3.276
- **Total de variáveis:** 10
- **Tema:** Parâmetros físico-químicos da água para avaliar sua qualidade

Passo 2: Avaliar a Qualidade dos Dados

Após importar o dataset, foi realizada a verificação da qualidade dos dados com foco na existência de valores ausentes. As colunas ph, Sulfate e Trihalomethanes apresentaram valores nulos.

Para garantir consistência na análise, adotou-se a estratégia de preenchimento com a mediana, por ser uma medida robusta a outliers e adequada para variáveis contínuas com distribuição assimétrica.

A limpeza dos dados é uma etapa fundamental para evitar erros nos modelos e viés nos resultados. Após o tratamento, foi confirmada a ausência de valores nulos com nova verificação.

```
[15] # Preencher valores ausentes com a mediana de cada coluna
df.fillna(df.median(), inplace=True)

# Verificar novamente se ainda existem valores nulos
df.isnull().sum()
```



	0
ph	0
Hardness	0
Solids	0
Chloramines	0
Sulfate	0
Conductivity	0
Organic_carbon	0
Trihalomethanes	0
Turbidity	0
Potability	0

dtype: int64

Passo 3: Avaliar o Comportamento das Variáveis


Com os dados já tratados, partiu-se para a análise exploratória das variáveis. O objetivo foi entender o comportamento de cada atributo, suas distribuições, possíveis outliers e relações entre eles.

Foram utilizados gráficos como:

- Matriz de correlação para verificar possíveis relações lineares entre os atributos.
- Histogramas para observar a distribuição das variáveis.
- Boxplots por cluster para analisar a variação de cada variável em relação aos grupos.
- Gráficos de densidade (KDE) e pairplots para avaliar a concentração e dispersão conjunta entre pares de variáveis.

Passo 3: Avaliar o Comportamento das Variáveis

A matriz de correlação mostra o grau de relação linear entre as variáveis do dataset. Como se observa, todas as correlações são fracas, com coeficientes próximos de 0, o que é favorável para clusterização (cada variável contribui com uma informação diferente). A única correlação negativa um pouco mais expressiva foi entre Sulfate e Solids (-0.15), mas ainda assim considerada fraca.




A correlação de Pearson varia entre -1 e +1. Valores próximos de 0 indicam fraca ou nenhuma correlação linear.

Passo 3: Avaliar o Comportamento das Variáveis

Após aplicar o algoritmo de clusterização (KMeans), os dados foram agrupados em três categorias distintas de qualidade da água. O gráfico ao lado demonstra a quantidade de regiões que pertencem a cada grupo:

- O Grupo 0 e o Grupo 1 concentram a maior parte das regiões, com aproximadamente 1.200 registros cada;
- O Grupo 2 contém menos registros, representando cerca de 900 regiões.

Essa divisão inicial indica que o modelo identificou padrões semelhantes de qualidade da água entre muitos pontos, mas também identificou um grupo com características mais distintas.




Passo 3: Avaliar o Comportamento das Variáveis

Para facilitar a interpretação dos dados após a clusterização, aplicou-se a técnica PCA (Análise de Componentes Principais), que reduz a dimensionalidade dos dados preservando a variabilidade mais relevante.


O gráfico mostra a distribuição das amostras em duas componentes principais, coloridas conforme os clusters atribuídos pelo KMeans:

- É possível observar uma separação clara entre os grupos, indicando que o modelo conseguiu identificar padrões distintos de qualidade da água.
- Os grupos 0 (verde), 1 (laranja) e 2 (azul) apresentam certa sobreposição, mas com regiões de maior densidade separadas, o que sugere características marcantes dentro de cada cluster.

Essa visualização reforça que a aplicação do KMeans foi eficaz para segmentar os dados em grupos com comportamentos semelhantes entre si.



Passo 3: Avaliar o Comportamento das Variáveis



Foram gerados boxplots para cada variável, segmentados por grupo (cluster), a fim de visualizar a distribuição e os padrões estatísticos dos dados.

Com isso, é possível observar:

- O grupo 0 apresenta maior concentração de Turbidez e Sólidos, indicando um possível risco de contaminação por partículas.
- O grupo 1 tende a ter valores medianos em quase todas as variáveis, sugerindo uma condição intermediária de potabilidade.
- O grupo 2 apresenta valores mais altos em Condutividade, Dureza e Carbono Orgânico, o que pode indicar presença elevada de sais e matéria orgânica na água.

Esses padrões reforçam que a clusterização conseguiu agrupar regiões com perfis distintos de qualidade da água, possibilitando a criação de estratégias mais direcionadas para cada grupo.


Passo 3: Avaliar o Comportamento das Variáveis

O gráfico mostra a distribuição da variável pH na base de dados utilizada.

Observa-se uma distribuição aproximadamente normal, com maior concentração de valores entre 6 e 8, que corresponde à faixa considerada segura para consumo humano, segundo a OMS.

A curva suavizada (KDE) reforça esse comportamento simétrico, indicando que a maior parte das amostras está próxima do pH neutro (7).

Isso sugere que, em geral, a água analisada não apresenta acidez ou alcalinidade extrema, sendo, nesse aspecto, adequada ao consumo, embora o pH isolado não seja suficiente para determinar potabilidade.



Passo 3: Avaliar o Comportamento das Variáveis

Este painel apresenta a distribuição das variáveis numéricas da base de dados.

Algumas variáveis apresentam uma distribuição aproximadamente normal, como:


- Hardness, Sulfate, Chloramines, Organic_carbon e Trihalomethanes.

Já outras apresentam assimetria ou caudas longas:

- *Solids* possui uma cauda à direita (distribuição assimétrica positiva), o que indica valores extremos de sólidos dissolvidos em algumas regiões.


A variável *Potability* é categórica binária (0 = não potável, 1 = potável) e mostra uma leve predominância de amostras não potáveis.

Essa visualização é importante para entender o comportamento geral dos dados antes da modelagem, ajudando na escolha de transformações ou técnicas de normalização se necessário.



Passo 3: Avaliar o Comportamento das Variáveis

Relações entre Variáveis e Distribuição dos Clusters



O gráfico mostra a relação entre as variáveis pH, Hardness, Solids e Conductivity, com uma amostra de 300 registros para facilitar a visualização.

- As distribuições diagonais revelam que a maioria das variáveis tem forma aproximadamente normal, mas com variações entre os clusters.
- As dispersões mostram que não há uma separação clara entre os clusters em todas as combinações de variáveis, mas algumas tendem a formar agrupamentos parciais.
- Condutividade e Sólidos, por exemplo, apresentam diferenciação visível no Cluster 2, com valores mais elevados.

Essa visualização auxilia na compreensão da interação entre os atributos e reforça que, embora alguns grupos tenham sobreposição, há padrões que justificam a clusterização.




Passo 3: Avaliar o Comportamento das Variáveis


O gráfico de densidade destaca o comportamento da variável Carbono Orgânico entre os clusters:

- O Cluster 1 apresenta os maiores níveis médios de carbono orgânico, com pico por volta de 16.
- O Cluster 2 mostra uma distribuição um pouco mais espalhada, mas também concentrada em valores elevados.
- O Cluster 0, por outro lado, concentra-se em valores ligeiramente menores, com o pico em torno de 13.

Essa análise sugere que os níveis de carbono orgânico podem estar relacionados ao nível de risco identificado, reforçando a necessidade de monitoramento ambiental contínuo.




Passo 3: Avaliar o Comportamento das Variáveis



O gráfico ilustra a correlação entre a dureza da água e a quantidade de sólidos dissolvidos, separando os dados por cluster:

- O Cluster 2 apresenta uma leve tendência positiva, indicando que regiões com maior dureza também tendem a ter mais sólidos.
 - Já o Cluster 0 exibe uma tendência negativa, com aumento da dureza associado à redução de sólidos.
 - O Cluster 1 apresenta uma tendência praticamente neutra.
- Essas diferenças ajudam a reforçar que os clusters representam perfis distintos de qualidade da água, com comportamentos únicos em relação aos parâmetros físico-químicos.




Passo 3: Avaliar o Comportamento das Variáveis

O gráfico apresenta a média da concentração de sulfato em cada grupo identificado na clusterização:

- O Cluster 1 apresenta a maior média de sulfato, seguido pelo Cluster 0.
- O Cluster 2 mostra a menor concentração média desse parâmetro.
- As barras de erro indicam o desvio padrão, refletindo a variabilidade interna de cada cluster.

O sulfato é um indicador relevante de possíveis contaminações e variações geológicas da água. Essas diferenças reforçam a distinção química entre os grupos identificados.



Passo 4 – Prepare os dados para uma análise mais detalhada

Antes da aplicação do modelo de clusterização, os dados passaram por uma etapa de pré-processamento.

Foram realizadas as seguintes ações:

- Exclusão de registros com valores ausentes;
- Padronização das variáveis numéricas por meio do método StandardScaler, garantindo que todas tivessem média zero e desvio padrão um;
- Seleção apenas das variáveis numéricas relevantes para o modelo, excluindo colunas que não contribuíam diretamente para a clusterização (como o rótulo de potabilidade).

Passo 5 – Escolha um modelo e aplique-o

O gráfico ao lado mostra a variação da inércia (soma das distâncias dos pontos ao centro de cada cluster) conforme o número de grupos (k) testados.


Percebe-se que, à medida que aumentamos o número de clusters, a inércia diminui, o que é esperado, já que os pontos ficam mais próximos de centros mais especializados.

No entanto, a partir de $k = 3$, a redução na inércia passa a ser menos expressiva. Esse ponto de inflexão no gráfico é conhecido como “cotovelo”, e representa uma boa escolha de quantidade de clusters, pois equilibra simplicidade do modelo com qualidade da segmentação.

Por isso, neste projeto foi adotado $k = 3$ como número ideal de grupos.

O algoritmo escolhido foi o K-Means, por sua capacidade de segmentar grandes volumes de dados numéricos de forma eficiente.

Sua simplicidade e compatibilidade com dados padronizados o tornam ideal para a análise exploratória proposta neste projeto.




Passo 6 – Refine o seu modelo

A clusterização agrupou as regiões em três perfis distintos de risco quanto à qualidade da água:

- Baixo Risco (35,9%):
Regiões com maior potabilidade e menores níveis de contaminantes.
- Médio Risco (36,1%):
Grupo mais frequente, com valores intermediários nas variáveis analisadas.
- Alto Risco (28%):
Regiões com maior concentração de sólidos, menor pH médio e menor potabilidade.

Essa classificação permite priorizar ações e direcionar recursos para as áreas mais críticas.




Passo 6 – Refine o seu modelo

O mapa de calor ao lado apresenta a média das variáveis analisadas em cada cluster, permitindo uma visualização clara das diferenças entre os grupos.

- O Cluster 2 (Alto Risco) destaca-se por apresentar a maior média de Sólidos (acima de 31.000), menor pH e uma potabilidade ainda preocupante.
- O Cluster 1 (Médio Risco) tem valores intermediários de condutividade, matéria orgânica e trihalometanos.
- O Cluster 0 (Baixo Risco) mostra pH mais equilibrado, menores teores de compostos orgânicos e melhor equilíbrio geral.

Essa análise complementa a clusterização, refinando a interpretação dos grupos e fornecendo subsídios para a definição de ações prioritárias.



Passo 6 – Refine o seu modelo

A tabela apresenta as médias das variáveis analisadas para cada cluster, consolidando os padrões identificados no processo de clusterização.

Essa visão quantitativa permite refinar a interpretação dos grupos e auxilia na criação de regras práticas de classificação com base em evidências.

Por exemplo:

- Se a turbidez e os sólidos totais estiverem acima de certos valores médios (como no Cluster 2), isso pode indicar uma região com maior risco de contaminação.
- Por outro lado, valores mais baixos nessas variáveis, combinados com maior pH e menor teor de carbono orgânico, podem indicar condições mais seguras, como observado no Cluster 0.


A partir desses dados, é possível criar critérios objetivos para classificar novas regiões e direcionar ações preventivas com base nos perfis médios identificados.



	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
Cluster										
0	7.22	208.72	18844.82	7.01	335.00	374.95	12.77	61.62	4.15	0.38
1	7.37	187.51	17936.28	7.48	351.55	460.28	15.63	71.32	3.70	0.39
2	6.53	191.98	31340.18	6.80	309.68	447.89	14.49	66.10	4.07	0.41



Passo 7 – Conclusão



A qualidade da água é um fator essencial para a saúde pública, o equilíbrio ambiental e o desenvolvimento sustentável. Este trabalho teve como objetivo central investigar como os parâmetros físico-químicos da água, como pH, turbidez, sólidos dissolvidos, sulfato, condutividade, entre outros, podem ser utilizados de forma sistemática e baseada em dados para avaliar e classificar sua potabilidade.

Após a importação e tratamento dos dados, a análise revelou que havia ausência de valores nulos, o que favoreceu a aplicação direta de técnicas estatísticas e de aprendizado de máquina. Os dados foram então padronizados com StandardScaler para garantir a comparabilidade entre variáveis com escalas distintas, uma etapa essencial para que os resultados não fossem distorcidos por magnitudes discrepantes.

A etapa exploratória mostrou variações significativas entre os parâmetros, o que já indicava a possibilidade de padrões distintos de qualidade da água entre as amostras. A seguir, aplicou-se o método do cotovelo para identificar o número ótimo de clusters, revelando que $k = 3$ era o ponto ideal, equilibrando simplicidade e desempenho do modelo.

Passo 7 – Conclusão

A clusterização permitiu segmentar as regiões em três grupos bem definidos:

- Cluster 0 (Baixo Risco): Representa 35,9% das regiões analisadas. Caracteriza-se por valores mais adequados de potabilidade e menores níveis de contaminantes.
- Cluster 1 (Médio Risco): O maior grupo, com 36,1% das regiões, apresenta níveis intermediários dos parâmetros físicos e químicos.
- Cluster 2 (Alto Risco): Engloba 28% das regiões, com concentração significativamente maior de sólidos e menor média de pH e potabilidade.


Esses agrupamentos foram validados visualmente por meio de gráficos de barras, boxplots e heatmaps, que reforçaram os padrões estatísticos detectados. O heatmap das médias por cluster, por exemplo, deixou evidente o contraste entre os grupos em variáveis como Solids, Trihalomethanes e Potability, reforçando a robustez da classificação.


Passo 7 – Conclusão

Ao final da análise, foi possível concluir que os parâmetros físico-químicos são ferramentas altamente eficazes na avaliação da qualidade da água e que o uso de técnicas de clusterização é extremamente útil para apoiar a tomada de decisão em saneamento e saúde ambiental.

A segmentação obtida fornece uma base prática para a priorização de ações corretivas e preventivas, permitindo direcionar esforços, recursos e políticas públicas às regiões mais vulneráveis, aquelas com maior risco à saúde devido à má qualidade da água.

Portanto, este estudo reforça a importância da coleta e análise sistemática de dados físico-químicos da água, não apenas para avaliação pontual de potabilidade, mas como ferramenta estratégica de gestão ambiental, vigilância sanitária e planejamento urbano.





Link Colab:

<https://colab.research.google.com/drive/1EuKtd9lKgYsaNpdblFnACajprPCn5e6A?usp=sharing>